

Modelado computacional de la dinámica de factores de transcripción en condrogénesis: SP1, RUNX2 y ETS1

Universidad Tecnológica Nacional, Facultad Regional Rosario

Abstract

El presente estudio desarrolla y valida un modelo computacional de la dinámica temporal de tres factores de transcripción clave en la condrogénesis (SP1, RUNX2 y ETS1). El modelo propuesto es un esquema simplificado y exploratorio diseñado para generar hipótesis y detectar tendencias generales en la dinámica de factores de transcripción, más que para ofrecer predicciones cuantitativas definitivas, por lo que sus resultados deben contrastarse con datos experimentales. Utilizamos un sistema de ecuaciones diferenciales ordinarias que combina términos de síntesis dependientes de una función sigmoide de activación y términos de degradación de primer orden. Las simulaciones se integraron con el método adaptativo LSODA (solve_ivp) sobre un horizonte temporal de 168 h con pasos de 0.5 h y condiciones iniciales basales. La búsqueda de parámetros óptimos se llevó a cabo mediante un algoritmo genético elitista (población inicial 42, 14 generaciones, elitismo = 3) con operadores de crossover y mutación ajustados por rango fisiológico. La función objetivo fue la distancia euclidiana frente a un vector target (SP1=0.9; RUNX2=1.0; ETS1=0.8), penalizando la complejidad y premiando la rapidez de alcance del objetivo. Incorporamos ruido biológico (RMS = 12%) para evaluar la robustez. El ajuste con AG+LSODA reproduce el perfil objetivo: RUNX2 responde rápido, SP1 se acumula lentamente y ETS1 es el más sensible. Para convertirlo en predicciones cuantitativas se requiere modelar ruido intrínseco/extrínseco, realizar análisis de sensibilidad e identificabilidad y validar trayectorias con muestreos temporales dirigidos.

Palabras Clave

Condrogénesis, Factores de transcripción, Ecuaciones diferenciales ordinarias (EDO), Algoritmo genético, Biología de sistemas.

Introducción

La condrogénesis es un proceso multicelular y temporalmente regulado donde la interacción de factores de transcripción define transiciones de estado desde progenitores neuroectodérmicos hasta condrocitos maduros. Comprender la dinámica conjunta de reguladores como SP1, RUNX2 y ETS1 es esencial para diseñar intervenciones en regeneración y modelado de enfermedades. Los modelos matemáticos permiten integrar producción, degradación e interacciones para explorar ventanas temporales críticas y predecir comportamientos emergentes bajo variabilidad estocástica.

Cabe señalar que el modelo propuesto constituye un modelo simplificado, cuyo propósito principal es explorar dinámicas plausibles y generar hipótesis, más que ofrecer predicciones cuantitativas definitivas. En este sentido, su valor radica en la capacidad de integrar conceptos y señalar tendencias generales que luego deberán contrastarse con datos experimentales.

Objetivos del estudio:

- Construir un modelo determinista-estocástico de la dinámica de SP1, RUNX2 y ETS1.
- Optimizar parámetros (producción, degradación, interacción) para

reproducir un perfil objetivo de proliferación condrocítica en 168 h.

- Evaluar la robustez frente a ruido biológico y proporcionar recomendaciones experimentales y computacionales.

Elementos del trabajo y metodología

Representación del sistema

Cada factor de transcripción i se describe por su concentración $y_i(t)$. La dinámica se define por la EDO:

$$\frac{dy_i}{dt} = \text{tasa producción} - \text{tasa degradación}$$
$$\text{tasa producción} = \text{producción}_i \times \text{activación}_i$$
$$\text{tasa degradación} = \text{degradación}_i \times y_i$$

donde la activación tiene la forma sigmoide:

$$\text{activación} = \frac{1}{1 + e^{1 - (\text{interacción} \times \Sigma y)}}$$

Este esquema captura umbrales no lineales y efectos cooperativos entre factores.

Parámetros iniciales y rangos fisiológicos

Se definieron tres bloques por proteína: Producción, Degradación e Interacción.

Los rangos empleados fueron:

- SP1:
 - Producción [0.10, 2.00];
 - Degradación [0.03, 0.30];
 - Interacción [-3.0, 3.0]
- RUNX2:
 - Producción [0.05, 1.50];
 - Degradación [0.05, 0.60];
 - Interacción [-4.0, 4.0]
- ETS1:
 - Producción [0.02, 1.00];
 - Degradación [0.10, 0.80];
 - Interacción [-3.0, 3.0]

Condiciones iniciales:

$$[\text{SP1}, \text{RUNX2}, \text{ETS1}] = [0.4, 0.05, 0.1].$$

Integración numérica

Se utilizó `solve_ivp` (SciPy) con método adaptativo LSODA para integrar durante 168 h con pasos efectivos de 0.5 h (336 pasos). LSODA permite alternar entre métodos explícitos e implícitos para manejar rigidez variable en sistemas bioquímicos.

Ruido biológico

Se añadió un término de ruido multiplicativo/porcentual con RMS del 12% para simular heterogeneidad intrínseca y micro-variaciones ambientales. Esto permite evaluar la robustez de soluciones óptimas.

Función objetivo y penalizaciones

Vector objetivo: [SP1=0.9, RUNX2=1.0, ETS1=0.8]. Se calculó la distancia euclidiana entre la trayectoria simulada (valor en $t = 168$ h o mínimo alcanzado) y el objetivo.

Penalizaciones y recompensas:

- Penalización por complejidad:
 $0.001 \cdot \text{suma de los absolutos de cada parámetro.}$
- Recompensa por alcanzar el target en $<5\%$: $-0.1 / t_{\text{reached}}$
(inversamente proporcional al tiempo de alcance).

La puntuación para selección de ruleta se transformó a $\text{score} = 1 / (1 + \text{fitness})$.

Optimización: algoritmo genético

Para la selección de hiper-parámetros, realizamos una comparación sistemática de configuraciones con el objetivo de identificar la combinación más eficiente (fitness mínimo y promedio en relación a las generaciones evaluadas) y más precisa (distancia al target según las generaciones evaluadas con respecto al total de generaciones en estudio). Se exploraron




Figura 1

valores de tamaño de población entre 10 y 100 individuos y un rango de número de generaciones entre 1 y 200. Asimismo, se evaluaron dos esquemas para la asignación inicial de parámetros: (i) el uso del valor central de cada rango y (ii) una distribución uniforme dentro de los rangos definidos. Optamos por la segunda estrategia, ya que reproduce de manera más realista variabilidad natural y el ruido estocástico inherentes a los sistemas biológicos.

- Población: 42 cromosomas
- Generaciones: 14
- Selección: torneo (opción ruleta) con elitismo de los 3 mejores
- Crossover: probabilidad 80%, constante $\alpha = 0.15$ (permite transgresión)
- Mutación: probabilidad por gen 15% con desvío estándar por tipo de parámetro:
 - Producción: 12% del rango
 - Degradación: 8% del rango

- Interacción: 20% del rango

Se ejecutó evaluación paralela (multiprocessing) y caché de resultados.

Resultados

Resumen ejecutivo. El algoritmo genético mostró (Figura 1) una mejora rápida durante las primeras generaciones y alcanzó su mejor solución en la generación donde $\min = 0.0689896$ (mejor fitness encontrada = 0.06898960179455751)

Evolución del algoritmo genético

La evolución registrada en las generaciones presenta una caída sostenida del mínimo de fitness desde Gen 0 ($\min = 0.6869$) hasta Gen 14 ($\min = 0.06899$), con variaciones en el valor promedio debido a individuos exploratorios y reevaluaciones en la población. El comportamiento típico fue de mejora rápida en las primeras 10 generaciones y refinamiento fino hasta la generación donde se reportó el mejor individuo.




Figura 2

Los parámetros numéricos del mejor individuo son:

SP1 Producción: 1.0593,
 SP1 Degradación: 0.1014,
 SP1 Interacción: -0.5374,
 RUNX2 Producción: 0.5631,
 RUNX2 Degradación: 0.5644,
 RUNX2 Interacción: 2.1109,
 ETS1 Producción: 0.5581,
 ETS1 Degradación: 0.5867,
 ETS1 Interacción: 0.943

Comparación final — Simulado vs Target

Valores finales (mejor individuo) y comparación con el vector objetivo utilizado:

Tabla 1. Comparación valores finales

Proteína	Simulado	Target	Error	Error relativo (%)
SP1	0.861	0.900	0.039	4.33 %
RUNX2	0.987	1.000	0.013	1.30 %
ETS1	0.774	0.800	0.026	3.25 %

La distancia euclidiana simple entre el vector simulado [0.861, 0.987, 0.774] y el vector objetivo [0.9, 1.0, 0.8] es aproximadamente 0.04864. Obsérvese que este valor no coincide numéricamente con el fitness reportado (0.06899), esto se debe

a que la función de fitness usada por el AG incorpora transformaciones o penalizaciones adicionales.

Trayectorias temporales (mejor individuo)

Las trayectorias temporales (Figura 2) extraídas del mejor individuo muestran las siguientes características principales:

- SP1 (Proteína 1): parte en 0.40 y asciende de forma monótona hacia una meseta cercana a 0.861; la subida es gradual, con desaceleración progresiva a lo largo del horizonte (0–168 h).
- RUNX2 (Proteína 2): parte en 0.05 y crece rápidamente, alcanzando valores próximos al target (~0.987) en fases tempranas (decenas de horas) y permaneciendo estable con pequeñas oscilaciones al final del periodo simulado.
- ETS1 (Proteína 3): parte en 0.10 y muestra un crecimiento intermedio que se aproxima a ~0.774; alcanza la meseta antes que SP1 pero más lentamente que RUNX2.

Interpretación dinámica

RUNX2 actúa como respuesta rápida del sistema (interacción neta positiva), lo que podría corresponder biológicamente a un regulador que se induce pronto en el proceso de maduración.

SP1 muestra respuesta lenta y escalonada (controla la escala temporal y la estabilidad final).

ETS1 alcanza un valor intermedio y actúa como modulador cuyo ajuste es crítico para acercarse al objetivo final (mayor error relativo entre los tres).

Robustez y observaciones

El valor final del fitness (0.06899) combinado con la pequeña distancia euclidiana (≈ 0.04864) sugiere un ajuste aceptable para los tres reguladores, con RUNX2 siendo el más precisamente ajustado y SP1/ETS1 mostrando pequeñas desviaciones relativas.

Discusión

Los resultados muestran un ajuste consistente y relativamente cercano al vector objetivo: la distancia euclidiana entre el estado simulado final [0.861, 0.987, 0.774] y el objetivo [0.9, 1.0, 0.8] es pequeña (~ 0.0486) y el AG reporta un fitness final razonablemente bajo (0.06899). Al tratarse de un modelo simplificado, su grado de veracidad es limitado; por ello no se obtiene una coincidencia temporal exacta con las etapas descritas en estudios experimentales sobre la trayectoria celular. Si se quiere reproducir aspectos biológicos no representados aquí para lograr una correspondencia temporal adecuada, es necesario enriquecer el modelo —por ejemplo incorporando niveles de ARNm y regulación post-transcripcional— y

re-parametrizar con datos temporales experimentales.

El análisis de los parámetros del mejor individuo aporta una explicación mecanicista a las trayectorias observadas. RUNX2 presenta una interacción neta fuertemente positiva (≈ 2.11) junto con una tasa de degradación moderada-alta (≈ 0.564), lo que produce una respuesta temprana y pronunciada seguida de estabilización: la interacción alta facilita la elevación rápida, mientras que la degradación limita la acumulación indefinida, generando el pico y la meseta temprana observada. SP1, con una producción elevada (≈ 1.06) y degradación baja (≈ 0.101), se acumula de forma más lenta y sostenida hasta alcanzar una meseta cercana al target, lo que explica la subida gradual de ese factor. ETS1 muestra parámetros intermedios (producción ≈ 0.56 , degradación ≈ 0.59 , interacción ≈ 0.94), que resultan en una dinámica intermedia y en un valor final algo por debajo del objetivo; su degradación relativamente alta respecto a su producción hace que su nivel final dependa de un equilibrio fino y lo vuelva más sensible a pequeñas variaciones de parámetros o a ruido de proceso.

Al tratarse de un modelo simplificado, el ruido biológico se ha representado aquí mediante un término promedio, una aproximación que homogeneiza la variabilidad intrínseca y puede ocultar heterogeneidades relevantes. Para enriquecer el modelo y capturar ruido estructurado es preferible sustituir ese término promedio por descripciones más realistas —por ejemplo, incorporando compartimentalización espacial (gradientes y transporte), vías de señalización adicionales que generen dependencia espacio-temporal, o modelos estocásticos

explícitos que distinguan ruido de proceso y ruido de observación—; estas extensiones permiten representar mejor la complejidad y la variabilidad observada experimentalmente.

Desde el punto de vista de robustez, el hecho de que las tres trayectorias queden próximas a los targets en presencia del esquema de optimización y del ruido empleado sugiere estabilidad general del comportamiento del modelo. No obstante, pequeñas perturbaciones en los parámetros de ETS1 (especialmente degradación e interacción) pueden provocar desviaciones relativamente importantes en su nivel final.

Técnicamente, hay limitaciones claras que condicionan la interpretación biológica: la función de activación utilizada (una sigmoide simple con un coeficiente agregado por proteína) resume distintas mecánicas en un único parámetro, lo que reduce interpretabilidad y favorece problemas de identificación estructural (múltiples combinaciones paramétricas pueden generar trayectorias similares).

Estrategias concretas que se derivan de estos hallazgos son: (1) realizar análisis de sensibilidad global (p. ej. Sobol o Morris) para identificar los parámetros que más contribuyen a la varianza explicada —probablemente ETS1_degradación y RUNX2_interacción— y orientar experimentos; (2) probar variantes de la función de activación (por ejemplo funciones tipo Hill con n y K_m ajustables) y distintos modelos de ruido (aditivo vs multiplicativo, ruido de proceso vs ruido de observación) para comprobar la robustez de las conclusiones; y (3) validar experimentalmente las predicciones temporales: muestreos tempranos (0–48 h) para confirmar la cinética de RUNX2 y

muestreos tardíos (≥ 96 –168 h) para validar la meseta de SP1 y la dinámica de ETS1.

Conclusión

El ajuste alcanzado por el esquema AG + LSODA proporciona una representación reproducible y aceptablemente cercana al perfil objetivo: RUNX2 se comporta como un regulador de respuesta rápida, SP1 como un acumulador lento y estable, y ETS1 aparece como el elemento más sensible del sistema, mostrando la mayor dependencia frente a pequeñas variaciones paramétricas. Para transformar estos hallazgos en predicciones cuantitativas y de uso experimental es necesario (y factible) incorporar un tratamiento explícito del ruido biológico, diferenciando sus componentes intrínsecos —propios de los procesos de transcripción y traducción— y extrínsecos —derivados de variaciones ambientales o entre células—, evaluando su impacto mediante propagación de incertidumbre y simulaciones estocásticas equivalentes al modelo determinista; realizar análisis de sensibilidad globales (Sobol, Morris) y locales para priorizar parámetros críticos, junto con estudios de identificabilidad estructural y práctica (matriz de información de Fisher y *profile likelihood*) que orienten el diseño experimental y permitan una estimación robusta de parámetros; y validar las trayectorias con muestreos temporales dirigidos, privilegiando ventanas tempranas para capturar la dinámica de RUNX2 y tardías para SP1 y ETS1, con un número suficiente de réplicas para cuantificar la variabilidad, estableciendo criterios de aceptación basados en métricas de ajuste y en la cobertura de intervalos de predicción.

Con esas etapas complementarias, el modelo se consolidará como herramienta útil para generar hipótesis y diseñar experimentos focalizados en condrogénesis.

Agradecimientos

Agradecemos a Camila Coronel y Bautista Buralli por sus valiosas discusiones y aportes en temas de biología, así como a Daniela Díaz y Víctor Lombardo por la tutoría y orientación brindada en el área de Algoritmos Genéticos. Este trabajo cuenta con el aval de la Cátedra de Algoritmos Genéticos de la Universidad Tecnológica Nacional, Facultad Regional Rosario.

Referencias

[1] Clavijo DC, Mejía BV, Rojas LM, Sáenz HL. *Análisis Estocástico de Un Sistema Génico Simple para la Síntesis de una Proteína Implementando los Métodos de Gillespie*. Revista Cuarzo 2018;24 (1) 7-16.

[2] Larry J. Eshelman, J. David Schaffer, *Real-Coded Genetic Algorithms and Interval-Schemata*. Philips Laboratories, North American Philips Corporation, 2014.

[3] Ryan N Gutenkunst *et al.*, *Universally Sloppy Parameter Sensitivities in Systems Biology Models*. Laboratory of Atomic and Solid State Physics, Cornell University, 2007.

[4] Timmy Manning, Roy D Sleator, Paul Walsh, *Naturally selecting solutions*. Department of Computer Science; Cork Institute of Technology, 2012.

[5] Zhang Y *et al.*, *Co-stimulation of the bone-related Runx2 P1 promoter in mesenchymal cells by SP1 and ETS transcription factors at polymorphic purine-rich DNA sequences (Y-repeats)*. Department of Cell Biology and Cancer Center, University of Massachusetts Medical School, 2008.

[6] Toshihisa Komori, *Runx2, an inducer of osteoblast and chondrocyte differentiation*. Histochem Cell Biol 149, 313–323 (2018)

[7] Petzold, L. R. (1983). *Automatic selection of methods for solving stiff and nonstiff systems of ordinary differential equations*. SIAM Journal on Scientific and Statistical Computing, 4(1), 136-148.

[8] Holland, J. H. (1992). *Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence*. MIT press.

[9] Elowitz, M. B., Levine, A. J., Siggia, E. D., & Swain, P. S. (2002). *Stochastic gene expression in a single cell*. Science, 297(5584), 1183-1186.