

Proyecto de Investigación - Algoritmos Genéticos

“Algoritmos Genéticos Elitistas para la optimización in silico de trayectorias de reprogramación celular hacia fenotipos condrogénicos”

Docentes:

Daniela Diaz

Victor Lombardo

Comisión:

303

Año de cursado:

2025

Integrantes:

Legajo	Nombre y Apellido	E-mail
47018	Eneas Paratore	eneasparatore@gmail.com
48808	Facundo Ramírez	facundomrb@gmail.com

Índice

Denominación del proyecto	3
Situación problemática	3
Problema	3
Objetivos de la investigación	3
Objetivo general	3
Objetivos específicos	3
Código y recursos disponibles en GitHub	4
Marco Teórico	4
Dogma central de la biología molecular	4
Factores de transcripción	5
Características de los factores de transcripción	6
Condrogénesis	7
Modelo Computacional y Metodología	8
Representación cromosómica	8
Rangos de parámetros por proteína	8
Dinámica de proteínas: ecuaciones diferenciales	9
Tabla de Concentración Funcional.	12
Función objetivo (fitness)	12
Algoritmo genético	13
Crossover	13
Mutación	13
Optimización computacional	14
Bibliografía	14

Denominación del proyecto

Desarrollo de un pipeline reproducible basado en Algoritmos Genéticos Elitistas para la optimización in silico de trayectorias de reprogramación celular hacia fenotipos condrogénicos.

Situación problemática

La reprogramación celular in silico es una herramienta clave para acelerar el diseño y la validación de hipótesis en medicina regenerativa. Sin embargo, la integración de modelos de optimización evolutiva con simulaciones multi-escala sigue siendo limitada, especialmente en entornos con recursos computacionales restringidos y plazos cortos. Actualmente no existen implementaciones ligeras, reproducibles y fácilmente adaptables que combinen Algoritmos Genéticos Elitistas (EGA) con evaluadores de trayectorias celulares simplificados para prototipado rápido.

Problema

¿Cómo desarrollar un sistema reproducible y eficiente que utilice Algoritmos Genéticos Elitistas para explorar y optimizar trayectorias de reprogramación celular hacia estados condrogénicos, integrando un evaluador computacional?

Objetivos de la investigación

Objetivo general

Diseñar, implementar y documentar un pipeline in silico reproducible que integre un núcleo de Algoritmo Genético Elitista con un evaluador simplificado de redes regulatorias génicas, para la optimización de trayectorias celulares desde estados neuroectodérmicos hacia fenotipos condrogénicos.

Objetivos específicos

1. Desarrollar un EGA para implementar un motor flexible y reproducible que permita obtener parámetros convenientes de producción, degradación e interacción.
2. Implementar un evaluador computacional ligero basado en un modelo ODE reducido de tres factores de transcripción.
3. Integrar el núcleo EGA con el evaluador en un flujo automatizado con configuración externa (`config.yaml`).

4. Ejecutar corridas de prueba y replicación para verificar convergencia, tiempos y estabilidad de resultados.
5. Documentar y empaquetar el sistema con scripts “one-click” y datasets generados (snapshots).

Código y recursos disponibles en GitHub

El código fuente se encuentra en el repositorio: <https://github.com/facumrb/EGA-Refactor>. En la carpeta *demo* se incluye el archivo **run_demo.py**, que permite ejecutar el algoritmo genético, utilizando el **config.yaml** (se pueden modificar los parámetros del archivo antes de realizar la ejecución); los datasets generados se almacenan automáticamente en la carpeta *snapshots*. La carpeta *plots* contiene los scripts para generar las distintas gráficas, que se guardan en *visuals*. La carpeta *presentation* incluye el material utilizado en la exposición; puede visualizarse abriendo el archivo **slide1.html** en un navegador y avanzar con la flecha derecha del teclado. Fuera de la carpeta *demo* se recomienda leer el **README.txt**, que contiene la guía de uso, la exploración de la carpeta *demo* y el acceso a **Guía.md**.

Marco Teórico

Dogma central de la biología molecular

Las **células** son para el cuerpo humano como pequeñas fábricas especializadas: cada una cumple funciones concretas para mantenernos vivos y en equilibrio. Dentro de la mayoría de ellas hay un “centro de control” llamado **núcleo**, y allí se encuentra el **ADN** (ácido desoxirribonucleico). El **ADN** es como una biblioteca gigantesca que guarda todas las instrucciones para construir y mantener el organismo. Sin embargo, el ADN no sale del núcleo: para que la información pueda usarse, primero debe **copiarse** en un formato más manejable. Ese formato es el **ARN mensajero (ARNm)**. El proceso de pasar la información del ADN al ARN se llama **transcripción**. Es como fotocopiar una página específica del libro de instrucciones para llevarla a la zona de producción de la célula. Una vez que el ARN mensajero sale del núcleo, llega a los **ribosomas** (las “máquinas ensambladoras” de la célula). Allí ocurre la **traducción**: el ARN se lee como un código que indica qué **aminoácidos** unir y en qué orden para formar una **proteína**.

Las **proteínas** son las piezas y herramientas fundamentales del cuerpo:

- Algunas forman estructuras (como el colágeno en cartílagos y piel).

- Otras actúan como enzimas, acelerando reacciones químicas vitales.
- También hay proteínas que transportan sustancias, defienden contra patógenos o regulan procesos celulares.

Así, el dogma central de la biología molecular establece que la información genética fluye en una sola dirección: del ADN al RNA, y de este a las proteínas. Este principio explica cómo la información contenida en los genes del ADN se traduce en moléculas funcionales que regulan los procesos vitales de las células y los organismos. En algunos casos, el RNA no es solo un mensajero pasivo; también puede ser un actor activo en la maquinaria que fabrica proteínas, y por eso es clave en la regulación de la actividad celular.

DOGMA CENTRAL

Propuesta inicial de Francis Crick (1970):



Modificaciones posteriores:



Factores de transcripción

Los factores de transcripción (TF, por sus siglas en inglés) son **proteínas sintetizadas en el citoplasma** (como cualquier otra proteína codificada por genes nucleares) que regulan la transcripción génica. Para que puedan actuar sobre el ADN, deben entrar al núcleo, y esto ocurre mediante un proceso regulado llamado **transporte nuclear**. Una vez dentro, los factores de transcripción llevan a cabo su función principal: **regular la expresión génica**. Regular la expresión génica es como tener un panel de control maestro para la vida celular: permite decidir **qué genes se encienden o apagan, cuándo y en qué cantidad**. Esto tiene consecuencias profundas tanto en el desarrollo como en la adaptación de un organismo. Esto implica:

- **Unión a secuencias específicas de ADN**

Generalmente en regiones promotoras o potenciadoras (*enhancers*) situadas antes del inicio del gen que regulan.

- **Reclutamiento de la maquinaria de transcripción**

Interactúan con la **ARN polimerasa II** y con **factores de transcripción generales** para iniciar la transcripción. La ARN polimerasa (ARNp) es una enzima que cataliza la transcripción, es decir, el proceso mediante el cual se copia una secuencia de ADN en una molécula de ARN. Esta molécula de ARN puede luego servir para producir proteínas o cumplir otras funciones celulares

- **Modificación de la cromatina**

La cromatina es el complejo formado por ADN y proteínas histonas que empaqueta el material genético dentro del núcleo.

Algunos TFs reclutan **coactivadores** o **correpresores** que modifican químicamente las histonas (por ejemplo, mediante **acetilación**, **desacetilación**, **metilación** o **fosforilación**) o remodelan la posición de los nucleosomas mediante complejos dependientes de ATP. Estas modificaciones, que forman parte de la **regulación epigenética**, no alteran la secuencia del ADN, pero sí cambian su empaquetamiento y, por tanto, la accesibilidad de las regiones promotoras y potenciadoras a la ARN polimerasa y otros reguladores.

- **Integración de señales**

Actúan como nodos que integran señales de distintas vías de señalización celular, ajustando la expresión génica a las condiciones internas y externas.

La **concentración** de un factor de transcripción en el núcleo, su **afinidad por las secuencias diana de ADN** y sus **interacciones con otras proteínas** determinan su capacidad reguladora. Estas propiedades influyen directamente en la intensidad de la transcripción de los genes blanco y, por ende, en la función celular.

Características de los factores de transcripción

En el estudio de la dinámica molecular, los factores de transcripción pueden describirse a partir de tres propiedades principales:

1. **Producción:** la tasa metabólica de síntesis de proteínas.
2. **Degradación:** la afinidad por el ADN y la estabilidad de las proteínas en el tiempo.
3. **Interacción:** la capacidad de interactuar con coactivadores o correpresores para modular la transcripción.

Estos parámetros, al ser cuantificables y simulables, permiten desarrollar modelos matemáticos y computacionales que representen con mayor fidelidad los mecanismos biológicos subyacentes.

Condrogénesis

La condrogénesis desde el neuroectodermo es una secuencia ordenada de estados celulares que va desde progenitores multipotentes hasta condrocitos maduros, atravesando condensación, diferenciación, proliferación y maduración/hipertrofia. El programa creado no considera maduración/hipertrofia. Cada etapa combina cambios morfológicos, reorganización de la matriz extracelular y reprogramación transcripcional; la dinámica temporal y la cooperación entre factores transcripcionales clave determinan el progreso y la estabilidad del destino condrogénico.

En el **estado neuroectodérmico** las células conservan plasticidad y muestran actividad basal de factores generales que sostienen proliferación y preparación transcripcional. Conforme progresa la trayectoria, durante la **condensación mesenquimal** las células migran y se agregan en nódulos precondrogénicos, reorganizan su citoesqueleto y aumentan moléculas de adhesión y matriz provisional. En esta fase SP1 y ETS1 actúan tempranamente promoviendo programas de adhesión y matriz, mientras RUNX2 comienza a elevarse desde niveles bajos hacia valores intermedios.

La **diferenciación a condroblastos** se caracteriza por el redondeo celular y el inicio de la síntesis masiva de matriz condrogénica (colágeno II, agrecano). Aquí la contribución de RUNX2 se hace más evidente y coopera con SP1 y ETS1 para activar los promotores de genes específicos de matriz. Durante la **proliferación condrocítica**, la actividad biosintética alcanza su pico y SP1 y RUNX2 funcionan de forma conjunta para mantener producción de matriz, con ETS1 modulando y afinando la expresión génica.

En la **maduración e hipertrofia** los condrocitos detienen el ciclo celular, aumentan su volumen y activan programas de maduración y remodelado de matriz; RUNX2 toma un papel central en estos procesos mientras SP1 y ETS1 disminuyen su influencia relativa aunque conservan funciones puntuales. Finalmente, la transición hacia calcificación y osificación implica el reemplazo del tejido condrogénico por tejido óseo, donde RUNX2 sigue presente como regulador de la maduración ósea.

A lo largo de estas etapas, las interacciones entre SP1, RUNX2 y ETS1 son complementarias y dinámicas:

- **SP1** mantiene una función generalista y sostenedora (proliferación, adhesión, componentes provisionales de matriz).
- **RUNX2** muestra una función creciente y escalonada, culminando como organizador de maduración e hipertrofia.
- **ETS1** actúa como cofactor modulador que afina respuestas y coopera con los otros dos en fases de condensación y producción de matriz.

La concentración funcional integrada de estos factores —resultado de producción, estabilidad e interacciones— varía en forma escalonada y sincroniza los cambios morfológicos y la producción de matriz que definen el fenotipo condrocítico. Desde el punto de vista práctico, modelar y cuantificar la dinámica temporal conjunta (más que los niveles aislados) permite identificar ventanas temporales críticas para intervención y apunta a estrategias más efectivas en regeneración y modelado de enfermedades.

Modelo Computacional y Metodología

Representación cromosómica

Para modelar la dinámica de los factores de transcripción, se definió un **cromosoma computacional** compuesto por tres grupos de parámetros, uno por cada proteína. Cada grupo incluye:

- **Tasa metabólica o concentración (producción)**
- **Constante de afinidad o eficiencia enzimática (degradación)**
- **Factor regulatorio (interacción)**

Rangos de parámetros por proteína

Los valores posibles para cada parámetro se definieron de la siguiente manera:

- **SP1**
 - Producción: [0.10, 2.00]
 - Degradación: [0.03, 0.30] ($\approx$ vida media 0.7–23 h)
 - Interacción: [-3.0, 3.0]
- **RUNX2**
 - Producción: [0.05, 1.50]
 - Degradación: [0.05, 0.60] ($\approx$ vida media 1.15–13.9 h)
 - Interacción: [-4.0, 4.0]
- **ETS1**

- Producción: [0.02, 1.00]
- Degradación: [0.10, 0.80] ($\approx$ vida media 0.87–6.93 h)
- Interacción: [-3.0, 3.0]

En general, la **producción** se ubica en un rango mayor cuando la proteína corresponde a un factor basal abundante, y en un rango menor cuando está fuertemente regulada por degradación. En el caso de **RUNX2**, se asignó un rango de interacción más amplio en magnitud, dado que puede funcionar como un “driver” capaz de impulsar con fuerza la expresión de otros factores de transcripción.

La distribución inicial de parámetros puede generarse de dos formas:

1. **Uniforme:** simulando la variabilidad natural de parámetros bioquímicos.
2. **Centrada:** representando condiciones homeostáticas equilibradas.

Priorizamos utilizar la distribución uniforme porque simula la variabilidad natural y el ruido estocástico inherentes a los sistemas biológicos. En la realidad, no todas las células de una población son idénticas; existen pequeñas fluctuaciones en las concentraciones de proteínas y en la fuerza de las interacciones. Esta estrategia captura esa diversidad inicial.

Dinámica de proteínas: ecuaciones diferenciales

La evolución temporal de las concentraciones de proteínas se modeló mediante un **sistema de ecuaciones diferenciales ordinarias (EDO)**.

Las EDOs describen tasas de cambio (dy/dt : tasa cambio de concentraciones de las proteínas respecto al tiempo), que biológicamente representan el balance entre síntesis (transcripción/traducción) y degradación de proteínas (factores de transcripción) en células, en función de sus interacciones con otras proteínas y su propia actividad.

EDO:

$$\frac{dy_i}{dt} = (\text{producción}_i \times \text{activación}_i) - (\text{degradación}_i \times y_i)$$

- *activación* se calcula en función de los factores regulatorios según:

$$\text{activación} = \frac{1}{1 + e^{1 - (\text{interacción} \times \Sigma y)}}$$

con Σ la suma de concentraciones proteicas actuales.

La activación se consigue mediante la función sigmoide. Esta función modela la modulación no lineal de la activación proteica, representando umbrales críticos en interacciones regulatorias, como en circuitos genéticos donde factores de transcripción activan o reprimen genes de manera cooperativa.

Término de Transcripción: $producción_i \times activación_i$ modela la síntesis del producto génico (transcripción y/o traducción).

- *Producción* (Producción basal): Representa la tasa de producción intrínseca o basal del gen. Es la velocidad a la que el gen se transcribiría si no estuviera bajo la influencia de ningún otro gen regulador. Se puede pensar en esto como la afinidad base de la ARN polimerasa por el promotor del gen.

- *Activación* (Regulación génica): Este es el término más importante para la dinámica de la red. Representa el efecto neto de todos los factores de transcripción (otros productos génicos en el modelo) sobre la expresión de este gen. Es un valor entre 0 y 1:

- Si Activación es cercano a 1, significa que los activadores dominan y el gen se está transcribiendo a su máxima capacidad.

- Si Activación es cercano a 0, significa que los inhibidores dominan y la transcripción del gen está reprimida o "apagada".

- Si Activación es 0.5, hay un equilibrio entre activación e inhibición.

Término de Degradación: $degradación_i \times y_i$ modela la eliminación o degradación del producto génico.

- *Degradación* (Tasa de degradación): Es una constante que representa la tasa intrínseca a la que el producto génico es degradado por la maquinaria celular (ej. por ARNasas para el ARNm o proteasas para las proteínas). Un valor alto de Degradación significa que la molécula tiene una vida media corta y desaparece rápidamente, mientras que un valor bajo significa que es estable y persiste por más tiempo.

- y (Concentración actual): Es la concentración actual del producto génico en la célula. La degradación es típicamente un proceso de primer orden, lo que significa que la velocidad de

eliminación es directamente proporcional a la cantidad de molécula presente. Cuanto más producto génico haya, más rápido se degradará en términos absolutos.

La integración numérica se implementó con el método **Adams/BDF** (función `solve_ivp` de *SciPy* con `method="LSODA"`), partiendo de las condiciones iniciales `[0.4, 0.05, 0.1]` (estado basal). Se emplearon **336 pasos de integración**, equivalentes a 168 horas con intervalos de 0.5 h. Cada iteración toma las concentraciones actuales de proteínas, calcula sus tasas de cambio a partir del balance entre síntesis regulada y degradación, y avanza el sistema en el tiempo para predecir nuevas concentraciones coherentes con la dinámica regulatoria y las constantes de estabilidad molecular.

El objetivo es que el sistema se aproxime a los valores *target* hacia la hora 168. En términos biológicos, a los **5–7 días** se espera observar:

- niveles proteicos sostenidos de **SP1, RUNX2 y ETS1** cercanos a los objetivos definidos,
- modificaciones epigenéticas que consolidan la expresión,
- inicio apreciable de secreción y organización de matriz extracelular, dependiendo del tipo celular y las condiciones experimentales.

El método LSODA, disponible en `solve_ivp`, es ampliamente utilizado en el modelado de procesos de biología molecular y expresión génica, donde suelen aparecer características como regulación no lineal (por ejemplo, funciones sigmoides), interacciones entre múltiples genes y proteínas, y escalas de tiempo muy distintas —como la transcripción rápida frente a la degradación lenta. Estas propiedades pueden provocar que el sistema se vuelva rígido en ciertos momentos de la simulación.

LSODA se destaca por su capacidad de adaptarse dinámicamente: emplea el método Adams-Bashforth-Moulton (explícito) cuando el sistema no es rígido, y cambia automáticamente al método Backward Differentiation Formula (BDF) (implícito) al detectar rigidez. Esta flexibilidad lo hace ideal para sistemas donde la rigidez no es constante.

Los métodos explícitos, aunque eficientes, pueden requerir pasos de integración extremadamente pequeños para mantener la estabilidad en regiones rígidas. Por otro lado, usar exclusivamente métodos implícitos puede resultar computacionalmente costoso en zonas donde no se justifica. LSODA resuelve este dilema al combinar lo mejor de ambos enfoques.

Ruido biológico. El “ruido” biológico es la variabilidad no determinista que se introduce en la regulación molecular y celular, incluso bajo condiciones genéticas idénticas. Se origina tanto en procesos moleculares intrínsecamente aleatorios (transcripción/traslación estocástica, fluctuaciones en la disponibilidad de factores) como en heterogeneidad ambiental (microvariaciones en el microambiente celular). En nuestro trabajo definimos un ruido de **12 % (RMS%)**, ya que este valor sitúa la variabilidad en un tramo en el que la heterogeneidad intracelular es apreciable pero no disruptiva: es un punto medio práctico que equilibra diferencias de ruido entre las distintas etapas del proceso y permite estudiar robustez sin destruir la señal funcional.

Tabla de Concentración Funcional.

Los siguientes valores cuantitativos (0 a 1) reflejan la concentración funcional combinada (síntesis relativa, estabilidad/degradación y nivel de interacción) de SP1, RUNX2 y ETS1 en cada etapa clave de la condrogénesis. Los valores reflejan una estimación ponderada basada en datos experimentales y revisiones, considerando momentos de máxima síntesis, estabilidad y capacidad de formar complejos funcionales (interacciones cooperativas con otras proteínas, especialmente en promotores génicos relevantes).

Etapas	SP1	RUNX2	ETS1
Estado neuroectodérmico	0.4	0.05	0.1
Condensación mesenquimal	0.7	0.3	0.6
Diferenciación a condroblastos	0.8	0.6	0.7
Proliferación condrocítica	0.9	1.0	0.8
Maduración / Hipertrofia	0.5	1.0	0.6
Calcificación / Osificación	0.2	0.8	0.3

Función objetivo (fitness)

El vector objetivo que representa el perfil idealizado de un condrocito maduro fue definido como:

- **SP1:** 0.9

- **RUNX2:** 1.0
- **ETS1:** 0.8

La **función fitness** se calculó como la distancia euclidiana entre los valores simulados y este vector objetivo. Además:

- Se penalizó la complejidad (suma de parámetros, ponderada por 0.001).
- Se otorgó una recompensa si en algún punto de la simulación la distancia al vector objetivo fue menor al 5% del valor objetivo (target), inversamente proporcional al tiempo en que alcanzó ese valor $(-0.1 / t_reached)$.

La puntuación para selección genética por ruleta se transformó en:

$$score = \frac{1}{1+fitness}$$

Algoritmo genético

El proceso de optimización utilizó un **algoritmo genético elitista** con las siguientes características:

- **Población inicial:** 42 cromosomas, 14 generaciones.
- **Selección:** torneo (con opción de ruleta).
- **Elitismo:** conservación de los 3 mejores individuos por generación.

Crossover

La probabilidad de cruce es de 80%. Aplicándolo con **constante alpha = 0.15**, lo que permitió extender el rango de valores más allá de los parentales (efecto de “trasgresión” biológica), esto permite descubrir soluciones novedosas más rápidamente⁸. Los hijos tomaron valores aleatorios en ese rango, respetando siempre los límites fisiológicos definidos.

Mutación

Cada gen tuvo una probabilidad del 15% de mutar. La mutación siguió una distribución normal con media en el valor actual y desvíos estándar ajustados según el rango de los límites iniciales (bounds) por parámetro. Desvíos estándar (mutation_scale):

- **Producción:** 12% * rango
- **Degradación:** 8% * rango

- **Interacción:** 20% * rango

Los valores mutados se mantuvieron dentro de los bounds.

La producción determina niveles absolutos de TF; necesita capacidad de exploración suficiente para ajustar magnitudes sin producir saltos inestables en la simulación. Un **~10–12%** del valor actual es heurísticamente efectivo en Algoritmos Elitistas para espacios continuos.

La degradación fija la escala temporal ($\tau \approx 1/k$; k = vida media de la proteína). Pequeños cambios absolutos en la degradación producen grandes cambios en dinámica/tiempos. Por eso la mutación debe ser más conservadora (**8%**) para no destruir la estructura temporal del sistema.⁵

Los coeficientes de interacción definen la fuerza y a veces la dirección de las regulaciones. Cambios en la interacción pueden transformar la topología funcional de la red (p. ej. de débil a fuerte activación). Por ello este parámetro necesita mayor step size (**20%**) para permitir reconfiguraciones que la mutación de producción o degradación no lograría. Es una práctica común reservar mayor amplitud de mutación para parámetros que definen la arquitectura regulatoria.⁶

Optimización computacional

Para mejorar la eficiencia, se implementó concurrencia con **multiprocessing**, evaluando el fitness en distintos núcleos de CPU en paralelo. Los resultados se almacenaron en una **caché**, evitando recalcular valores previamente procesados.

Durante la ejecución se registraron:

- Fitness mínimo y promedio por generación,
- Tiempo de procesamiento total,
- Parámetros de la mejor solución encontrada.

Bibliografía

1. <https://pubmed.ncbi.nlm.nih.gov/16390320/>
2. <https://academia-lab.com/enciclopedia/factor-de-transcripcion/>
3. <https://www.genome.gov/es/genetics-glossary/Central-Dogma>
4. <https://www.sciencedirect.com/science/article/abs/pii/B9780080948324500180>
5. <https://pmc.ncbi.nlm.nih.gov/articles/PMC2000971/>

6. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3813526/>
7. [Co-stimulation of the bone-related Runx2 P1 promoter in mesenchymal cells by SP1 and ETS transcription factors at polymorphic purine-rich DNA sequences \(Y-repeats\). - Abstract - Europe PMC](#)
8. [ETS1__AcademiaLab](#)
9. [Runx2, an inducer of osteoblast and chondrocyte differentiation | Histochemistry and Cell Biology](#)
10. [Factor de transcripción Sp1__AcademiaLab](#)
11. [El Dogma Central de la Biología molecular Síntesis de Proteínas](#)
12. [Factores de transcripción | La guía de Biología](#)